Além da pesquisa textual usando o elasticsearch para Bl

George Tavares

Arquiteto na Softplan





Seja softplayer!

Uma das majores desenvolvedoras de software do país

Quase 2.000 softplayers no Brasil e no Mundo Guiamos organizações públicas e privadas na busca por mais eficiência

Sede em Florianópolis

Trabalho 100% remoto ou híbrido

Fundada há 30 anos por três amigos

Eleita uma das melhores empresas para se trabalhar pela GPTW Entre gigantes e startups, escolhemos o melhor de cada lado: solidez e flexibilidade

Promovemos diariamente transformações na vida de milhares de pessoas

TEMOS VAGAS!

softplan.com.br/carreira

Developer

.NET; Phyton; JAVA: React.

Full Stack Developer

Product Owner

Product Designer | UX

Chief Architet

Agile Master

KAHOOT

- Usar 2 monitores, ou separar bem o youtube e as opções de respostas
- Quando a Priscila estiver lendo as resposta, colocar o youtube 2x para ficar proximo da próxima pergunta
- Acertar as perguntas

Banco de dados

- Banco de dados tradicionais são organizados em linhas, porém análise de dados, usando group by star schema, acessa os dados em colunas.
- Solução : criar índices Duplica dados e resolve somente para as colunas que foram criado índice
- Por que n\u00e3o armazenar somente os \u00edndices ent\u00e3o, esquecer as linhas?
- Lucene também apresenta uma estrutura semelhante para armazenamento

Organização dos dados

Open Source:

- MonetDB
- MariaDB ColumnStore (InfoBright)
- Postgres Citus DB

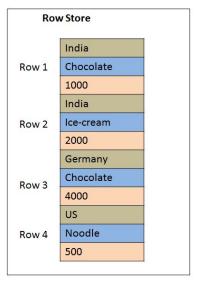
Comercial

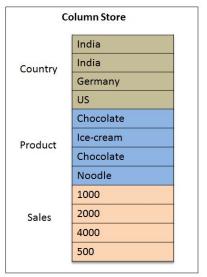
- SAP Hana
- HP Vertica
- SQL Server columnstore index
- Oracle IM column store

NoSQL

ElasticSearch







Fragmento da base de dados de censo americano de 1990 - 2.458.285 registros - 69 colunas

```
caseid, dAge, dAncstry1, dAncstry2, iAvail, iCitizen, iClass, dDepart, iDisabl1, iDisabl2, iEnglish, iFeb55, iFertil, dHispanic, dHour89, dHours, iImmigr, dIncome1, dIncome2, dIncome3, dIncome4, dIncome5, dIncome6, dIncome7, dIncome8, dIndustry, iKorean, iLang1, iLooking, iMarital, iMay75880, iMeans, iMilitary, iMobillim, dOccup, iOthrserv, iPerscare, dPOB, dPoverty, dPwgt1, iRagechld, dRearning, iRelat1, iRelat2, iRemplpar, iRiders, iRlabor, iRownchld, dRpincome, iRPOB, iRrelchld, iRspouse, iRvetserv, iSchool, iSept80, iSex, iSubfam1, iSubfam2, iTmpabsnt, dTravtime, iVietnam, dWee k89, iWorklwk, iWWII, iYearsch, iYearwrk, dYrsserv
```

+	+	+		+	++	+	+	+	++		+
Field	Туре	Null	Key	Default	Extra	Field	Type	Null	Key	Default	Extra
caseid	bigint(20)	YES		NULL	 	d0ccup	bigint(20)	YES	 	NULL	
dAge	bigint(20)	YES		NULL	i i	iOthrserv	bigint(20)	YES	i i	NULL	i I
dAncstry1	bigint(20)	YES		NULL	i i	iPerscare	bigint(20)	YES	i i	NULL	i I
dAncstry2	bigint(20)	YES		NULL	i i	i dP0B	bigint(20)	YES	i i	NULL	i İ
iAvail ´	bigint(20)	YES		NULL	i i	dPoverty	bigint(20)	YES	i i	NULL	i İ
iCitizen	bigint(20)	YES		NULL	i i	dPwgt1	bigint(20)	YES	i i	NULL	i İ
iClass	bigint(20)	YES		NULL	i i	iRagechld	bigint(20)	YES	i i	NULL	i İ
dDepart	bigint(20)	YES		NULL	i i	dRearning	bigint(20)	YES	i i	NULL	İ
iDisabl1	bigint(20)	YES		NULL	i i	iRelat1	bigint(20)	YES	i i	NULL	İ
iDisabl2	bigint(20)	YES		NULL	i	iRelat2	bigint(20)	YES		NULL	ĺ
iEnglish	bigint(20)	YES		NULL	i	iRemplpar	bigint(20)	YES		NULL	
iFeb55	bigint(20)	YES		NULL	i i	iRiders	bigint(20)	YES	i i	NULL	İ
iFertil	bigint(20)	YES		NULL	i i	iRlabor	bigint(20)	YES	ĺ	NULL	İ
dHispanic	bigint(20)	YES		NULL	i i	iRownchld	bigint(20)	YES		NULL	ĺ
dHour89	bigint(20)	YES		NULL	i i	dRpincome	bigint(20)	YES		NULL	ĺ
dHours	bigint(20)	YES		NULL	i i	iRPOB	bigint(20)	YES		NULL	ĺ
iImmigr	bigint(20)	YES		NULL		iRrelchld	bigint(20)	YES		NULL	
dIncome1	bigint(20)	YES		NULL		iRspouse	bigint(20)	YES		NULL	
dIncome2	bigint(20)	YES		NULL		iRvetserv	bigint(20)	YES		NULL	
dIncome3	bigint(20)	YES		NULL		iSchool	bigint(20)	YES		NULL	
dIncome4	bigint(20)	YES		NULL		iSept80	bigint(20)	YES		NULL	
dIncome5	bigint(20)	YES		NULL		iSex	bigint(20)	YES		NULL	
dIncome6	bigint(20)	YES		NULL		iSubfam1	bigint(20)	YES		NULL	
dIncome7	bigint(20)	YES		NULL		iSubfam2	bigint(20)	YES		NULL	
dIncome8	bigint(20)	YES		NULL		iTmpabsnt	bigint(20)	YES		NULL	
dIndustry	bigint(20)	YES		NULL		dTravtime	bigint(20)	YES		NULL	
iKorean	bigint(20)	YES		NULL		iVietnam	bigint(20)	YES		NULL	
iLang1	bigint(20)	YES		NULL		dWeek89	bigint(20)	YES		NULL	
iLooking	bigint(20)	YES		NULL		iWork89	bigint(20)	YES		NULL	
iMarital	bigint(20)	YES		NULL		iWorklwk	bigint(20)	YES		NULL	
iMay75880	bigint(20)	YES		NULL		iWWII	bigint(20)	YES		NULL	
iMeans	bigint(20)	YES		NULL		iYearsch	bigint(20)	YES		NULL	
iMilitary	bigint(20)	YES		NULL		iYearwrk	bigint(20)	YES		NULL	
iMobility	bigint(20)	YES		NULL		dYrsserv	bigint(20)	YES		NULL	
iMobillim	bigint(20)	YES		NULL		+	+	+	+		+

Mysql

```
MariaDB [test]> select dAge,count(*) from census group by dAge order by 1;
+----+
| dAge | count(*) |
+----+
| 0 | 32169 |
| 1 | 441248 |
| 2 | 242511 |
| 3 | 370955 |
| 4 | 404535 |
| 5 | 312825 |
| 6 | 331258 |
| 7 | 322784 |
+----+
8 rows in set (3.856 sec)
```

Mysql - indice no dAge

```
MariaDB [test]> select dAge,count(*) from census group by dAge order by 1;
+----+
| dAge | count(*) |
+----+
| 0 | 32169 |
| 1 | 441248 |
| 2 | 242511 |
| 3 | 370955 |
| 4 | 404535 |
| 5 | 312825 |
| 6 | 331258 |
| 7 | 322784 |
+----+
8 rows in set (1.170 sec)
```

Mysql - indice no dAge

```
MariaDB [test] > select dAge, iSex, count(*) from census group by dAge, iSex order by 1,2;
 dAge | iSex | count(*)
                  16419
                  15750
                 225807
                 215441
     2 |
                 124344
                118167
                185246
                 185709
                 198566
                 205969
                 152989
                159836
                 157523
                 173735
                  130707
                  192077
16 rows in set (3.988 sec)
```

MonetDB - verificar

MonetDB

16 tuples (38.761ms)

```
sql>select dAge,iSex,count(*) from census group by dAge,iSex order by 1,2;
 dage | isex | L4
           0 | 16419
           1 | 15750
           0 | 225807
           1 | 215441
           0 | 124344
           1 | 118167
           0 | 185246
           1 | 185709
           0 | 198566
           1 | 205969
           0 | 152989
           1 | 159836
           0 | 157523
           1 | 173735
           0 | 130707
           1 | 192077
```

MonetDB

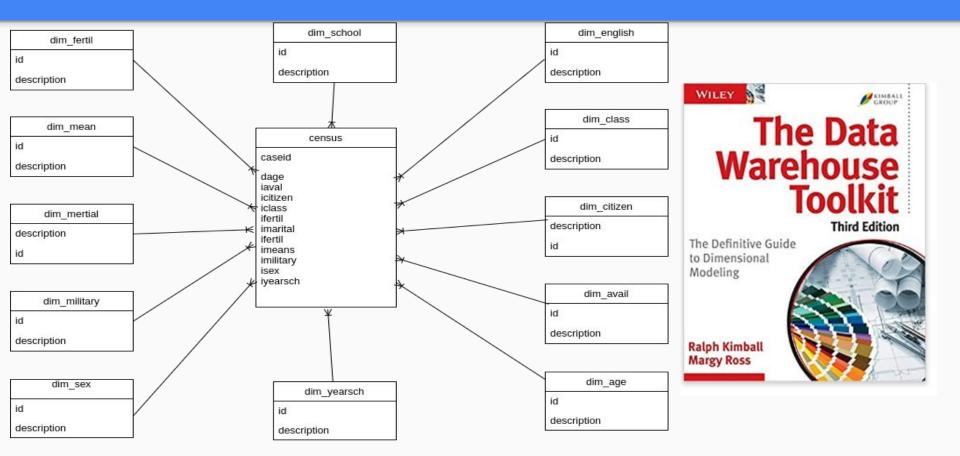
sql>select dPOB,dOccup,iClass,dIndustry,count(*) from census group by dPOB,dOccup,iClass,dIndustry order by 1,2,3,4;

+	+			+	-++	
dpc	b	doccup	class	dindustry	L6	
+====	===+	·======-		+========	=+======+	
	0	0	0	0	927701	
Ì	0	1	1	1	1156	
ĺ	0	1	1	2	1462	
Ì	0	1	1	3	6382	
Ì	0	1	1	4	35298	
Ì	0	1	1	5	10166	
İ	0 j	1	j 1	6	6530	
•••						
1	6	8	9	12	32	
+	+			+	-+	
2152 tuples (77.587ms)						

Elastic

- 1. Criar um indice otimizado
- 2. Realizar um job no logstash para importar
- 3. Verificar o tempo das consultas

Modelo ER - Star Schema



https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/books/data-warehouse-dw-toolkit/

Seleção de ferramentas

Banco de Dados	MonetDB	SAP Hana SQL Server column index	ELK
Ferramenta OLAP	Mondrian	Analysis Server	Elastic Search
Ferramenta ETL	Pentaho Data Integration	Integration Services	Logstash
Ferramenta Visualização	Saiku BA Pentaho BA	Tableau PowerBl	Kibana

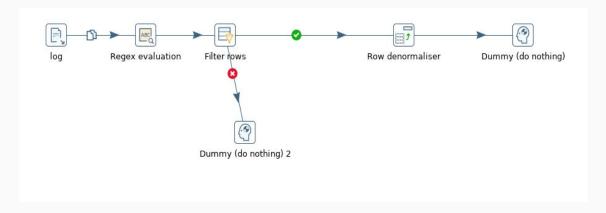
ETL - Logstash

Input: file Filter: csv

> prune translate

Output: elasticsearch

Pentaho PDI



Visualização - Kibana

Saiku

Info: 09:01 / 3 x 10 / 0.02s Adicionar Medidas 400,000 this. 350,000 -No of to all Condução para o Trabalho Disponibilidade Trabalho 250,000 -▶ Estado Civil ▼ Faixa Etaria 200,000 -Faixa Etaria Faixa Etaria 150,000 -*** ▶ Fluencia Inglés Formação escolar 0 000 000 Genero ▶ Militar Nacionalidade Nivel escolar Número de filhos ▶ Tipo Emprego

Kibana



Nenhuma solução é a bala de prata.

Mysql/Relacinal	OLTP Transacional	Não adequado para analytics
Monet/Colunar	OLAP Suporta SQL	Lento para inclusão de registros (d-1)
ELK	Bom para analise Tempo de ingestão bom	Não transacional Sem SQL

Obrigado!

George Tavares @tanquetav https://github.com/tanquetav

https://github.com/tanquetav/census

https://softplan.com.br/carreira